



Classification Multimodale

Produits E-Commerce — Challenge Rakuten

France

Approche hybride combinant **texte** et **image** avec un système de vote innovant pour classer automatiquement des produits parmi 27 catégories.

84 916

Produits

27

Catégories

~79%

Image

83%

Texte

Johan Frachon • Liviu Andronic • Hery M. Ralaimanantsoa • Oussama Akir

Mentor : Antoine — Février 2026

— L'Equipe & Contributions

Johan Frachon

Pipeline Image & Voting System

- DINOv3 + MLP (79.43%)
- EfficientNet-B0 & XGBoost
- Calibration Sharpening

Liviu Andronic

NLP & Expert Technique

- LinearSVC (83%)
- Fusion multimodale (F1~0.85)
- GridSearch, SHAP

Hery M. Ralaimanantsoa

Donnees & Preprocessing Texte

- Exploration dataset (84 916 produits)
- Nettoyage HTML, gestion NaN
- TF-IDF 280K features

Oussama Akir

Image & Integration

- Pipeline image
- Application Streamlit
- Multimodal, Demo

Mentor : Antoine — Liora

Le Probleme

Classification manuelle : **5 min/produit**, 10-15% d'erreur, non-scalable pour des millions de produits.

Notre Solution

IA multimodale : **<1s/produit**, 27 categories, F1~0.85, deploiement Streamlit.

Soutenance RNCP — Ingenieur Machine Learning

Liora — Promotion Octobre 2025. **Plongeons dans la technique.**

Le Challenge Rakuten France

Objectif

Classifier automatiquement des produits e-commerce parmi **27 categories** en utilisant texte + image.

Enjeux Business

- Améliorer l'expérience de recherche
- Réduire le taux de rebond
- Automatiser millions de produits/jour
- Traiter données multilingues

84 916

Produits Train

13 812

Produits Test

27

Categories

35%Descriptions
NaN

Metric d'évaluation

F1-Score weighted : prend en compte le déséquilibre des classes.

Le Dataset en Chiffres

84 916

Produits Train

27

Categories

5

Langues

35%

Descriptions NaN

500×500

Images px


13×

Ratio Desequilibre

Texte : designation + description (courte, 8 mots en moyenne). **Image** : photos produit JPEG.

DONNEES

Desequilibre des Classes




13×

Ratio
Max/Min

3 145

Moyenne/Classe



`class_weight='balanced'`

F1 weighted

Oversampling



HTML+NaN



Clean



Concat



TF-IDF

→ Nettoyage HTML, suppression accents, gestion NaN (35%)

→ Detection de langue (5 langues) + traduction FR

→ FeatureUnion : Word n-grams (1,2) + Char n-grams (3,5)

→ **Pas de lemmatisation** — preserve les marques (iPhone, PlayStation)

Resultat : 280K features TF-IDF — robuste aux fautes, au multilingue, et aux noms de marques.

PIPELINE

Preprocessing Image — Transfer Learning



500×500



224×224



Normalize



Features

DINOv3

ViT-Large self-supervised (Meta)

1024 features

EfficientNet

CNN B0 lightweight (5.3M params)

1280 features

ResNet50

Feature extractor pour XGBoost

2048 features

Normalisation ImageNet (mean/std). Pas de fine-tuning : extraction de features directe.

Positionnement vs Etat de l'Art

Approche	Architecture	Fusion	F1	Contrainte
Gagnant Rakuten 2020	CamemBERT + ResNet152	Late Fusion	91.4%	GPU massif
SOTA 2024-2025	Transformers multimodaux	Attention fusion	94-95%	Infrastructure lourde
Notre approche	TF-IDF + Voting + Late Fusion	Late Fusion	~85%	CPU-friendly

Pourquoi 85% et pas 91% ?

Nos choix : pas de CamemBERT (GPU), pas de fine-tuning (temps), interprétabilité (SHAP).

Notre avantage

Deployable, interprétable, **<1s inference sans GPU** pour le texte.

IMAGE

Modelisation Image — ML vs Deep Learning

Modele	F1-Score	Temps	Hardware	Verdict
Random Forest	0.71	~30 min	CPU	Baseline
XGBoost GPU	0.72	~10 min	GPU	Standard
XGBoost Heavy	0.765	6 heures	CPU 128GB	Plafond ML
DINOv3 + MLP	0.794	58 sec	GPU	Rupture

Plafond ML

Les modeles classiques plafonnent a ~76% malgre 6h de calcul.


Rupture Deep Learning

DINOv3 + MLP atteint **79.43%** en 58 secondes sur GPU RTX 4070.

IMAGE

Architecture Voting — Ensemble Image

Trois architectures complémentaires combinées par **Voting pondéré** pour la robustesse.



3 architectures orthogonales

Transformer (DINOv3), CNN (EfficientNet), Gradient Boosting (XGBoost)

Complementarite des Modeles

DINOv3 — Le Patron

Vision Transformer

Contexte global, poids
4/7

79.43% seul

EfficientNet — L'Expert

CNN

Textures locales,
poids 2/7

66.63% seul


XGBoost — Le Statisticien

Gradient Boosting

Features tabulaires,
poids 1/7


85.32% seul

Comment chaque modele voit la meme image




Calibration — Le Sharpening

AVANT — Le Probleme



XGBoost (vert) groupe a ~25% → seuil 80% jamais atteint

APRES — Sharpening



XGBoost calibre → décisions nettes au-delà du seuil

$$p_{\text{sharp}} = p^3 / \Sigma(p^3)$$

Concentre la probabilité sur la classe dominante

Resultat

Après sharpening : le Voting est mieux calibre, **~70% d'automatisation** au seuil de 80%.

**DINOv3 + MLP****79.43%**

Poids 4/7

**XGBoost****85.32%**

Champion

**EfficientNet****66.63%**

Poids 2/7

**VOTING****~79%**


Diversite

Le role du Voting

Le Voting (~79%) ne bat pas XGBoost individuel (85%). Son role : **robustesse architecturale et diversite**. Quand un modele se trompe, les autres compensent.

TEXTE : Quel classifieur ?

Chaque choix technique resulte d'un **arbitrage raisonne** entre performance, complexite et contraintes.



Principe directeur

Le gain potentiel de CamemBERT (~1-2%) ne justifie pas la complexite (GPU, 200ms, boite noire). **LinearSVC = meilleur compromis.**

Modele	F1-Score	Temps
Logistic Regression	0.79	~2 min
Multinomial NB	0.76	~30 sec
LinearSVC (C=0.5)	0.83	~3 min
Random Forest	0.68	~15 min


83%

Accuracy LinearSVC

Champion Texte

LinearSVC avec `class_weight='balanced'` et `C=0.5` optimise par GridSearch.

Fusion Multimodale — Late Fusion



Exemple Synergie

Image : Forme ronde bleue → "Piscine" ❌

Texte : "DVD Le Grand Bleu" → "DVD" ✔

Fusion : Le texte corrige l'erreur visuelle

Configuration	Accuracy
Texte seul	83%
Image seule	~79%
Fusion Multimodale	F1 ~ 0.85

Exemple : "iPhone 15 Pro Max 256GB"



Prediction : **Telephones (94.2%)**



SHAP (Shapley Values)

Identifie les mots-cles qui poussent vers chaque categorie. Interpretation directe grace aux coefficients LinearSVC.


Explicabilite — Grad-CAM (Image)

Rapport Technique Grad-CAM


RAPPORT TECHNIQUE : image_572771_product_996055.jpg



Confiance et Prédiction par Modèle



Focus Battle — 4 Modeles



Les zones **rouges** = zones decisives pour la prediction. Conformite AI Act :
transparence algorithmique, droit a l'explication.

Data Leakage — Integrite Scientifique

Decouverte

Les scores image etaient gonfles a **92%** (data leakage dans l'evaluation).

Correction

Audit complet, chaque fichier, chaque slide, chaque metrique.
Score reel : **79.28%**.

92%

Gonfle (leakage)



79.28%

Correct (audite)

Demarche d'ingenieur

C'est la difference entre un projet academique et une demarche d'ingenieur.

L'integrite avant la performance.

210+

Tests

85%

Coverage

50+Securite
OWASP**6/6**

Quality Gates

Pyramide de Tests

- Unitaires (90)
- Integration (30)
- ML / Performance (40)
- Securite OWASP (50)

Quality Gates ML

- Accuracy 79.3% ✓
- F1 Macro 78.5% ✓
- Latence <100ms ✓
- 27/27 classes ✓

Ce que ce projet nous a appris en tant qu'**ingenieurs ML**.

Ce qu'on referait autrement

1. **Commencer par la fusion** des le debut, pas apres avoir finalise chaque pipeline separement
2. **Implementer le monitoring** des metriques des le premier modele
3. **Tester l'OCR** sur les images-texte avant d'investir dans le fine-tuning image

Erreurs instructives

1. **ResNet "Phoenix"** : 91% train, 65% test. Lecon : surveiller le gap train/val
2. **Labels desalignes** : 3 referentiels incompatibles. Lecon : standardiser le mapping
3. **XGBoost non calibre** : probabilites "molles" diluaient le vote

Competences acquises

Vision Transformers

Self-Supervised Learning

Ensemble Calibration

Multimodal Fusion

RESULTATS

Impact Business

AVANT (Manuel)

5 min/produit, 10-15% erreur,
non scalable

APRES (IA)

<1s/produit, ~85% F1, 100K+
produits/jour

~70%

Automatisation

30%

Revue humaine

500K+

Produits/jour GPU

Seuil de confiance

Le systeme sait dire "je ne suis pas sur". **Zero automatisation aveugle** — seuil de confiance 80%.

Conclusion & Perspectives

~79%

Image Voting

83%

Texte SVC

F1~0.85

Fusion

Perspectives d'amélioration

OCR (+3-5%)

CamemBERT (à évaluer)

Fine-tuning DINOv3

Déploiement Cloud

DEMO

Place à la Demonstration

Vous connaissez la theorie. **Oussama** va maintenant vous montrer le systeme en action.



1. Texte seul

"Harry Potter edition poche"
→ **Livres (99%)**

Le texte suffit



2. Image seule

Photo bouee piscine
→ **Piscine (~79%)**

Le Voting decide



3. Fusion

"DVD Le Grand Bleu"
+ jaquette bleue
→ **DVD (87%)**

Texte corrige
image

Application Streamlit

Predictions en temps reel • 3 modalites • Explicabilite integree • F1~0.85

Merci !

Questions ?

84 916

Produits

27

Categories

3

Modeles

F1~0.85

Fusion

Johan Frachon • Liviu Andronic • Hery M. Ralaimanantsoa • Oussama Akir

Mentor : Antoine — Liora — Fevrier 2026